IDENTIFICACIÓ D'IDIOMES AMB TÈCNIQUES DE PROCESSAMENT DE LLENGUATGE

Carlos Palazón, Ferran Òdena

0. Taula de Continguts

- 0. Taula de Continguts
- 1. Introducció
- 2. Dades del problema
- 3. Preprocessament
- 4. Implementació dels models
  - 4.1 Lidstone Smoothing
    - 4.1.1 Implementació
    - 4.1.2 Refinament del paràmetre lambda
    - 4.1.3 Anàlisi dels resultats i errors
  - 4.2 Interpolation Smoothing
    - 4.2.1 Implementació
    - 4.2.2 Anàlisi dels resultats i errors
- 5. Conclusions

1. Introducció

El reconeixement automàtic d'idiomes és una tasca fonamental dins del camp del Processament del Llenguatge Natural (NLP) que permet categoritzar textos desconeguts cap a la llengua corresponent. L'objectiu principal d'aquesta pràctica és dissenyar, implementar i avaluar un model estadístic generatiu capaç de predir l'idioma d'un document donat. Per assolir-ho, es construeix un model de llenguatge basat en seqüències de caràcters, concretament utilitzant trigrames, ja que capturen eficaçment les estructures morfològiques pròpies de cada idioma sense dependre de diccionaris complets de paraules. Concretament, s'apliquen les tècniques de suavització Lidstone i Interpolation per a gestionar els problemes de zero probabilitat associats a trigrames no observats durant l'entrenament. Aquestes tècniques permeten que el model pugui generalitzar millor a textos desconeguts, assignant probabilitats raonables fins i tot a trigrames que no s'han vist abans. A més de la construcció bàsica del model basada en freqüències, s'aprofondeix en l'optimització dels seus hiperparàmetres mitjançant tècniques de validació creuada sobre el conjunt d'entrenament, per tal de prevenir el sobreajustament (overfitting). Finalment, es fa una rigorosa avaluació sobre un conjunt de dades independent, posant èmfasi no només en el percentatge d'encert (accuracy), sinó en una anàlisi detallada de la matriu de confusió i els possibles motius darrere de les classificacions errònies del model.

2. Dades del problema

El sistema s'entrena a partir de col·leccions de text proporcionades per la *Leipzig Corpora Collection*. Aquest projecte recopila textos de manera automàtica d'Internet (principalment articles de notícies i pàgines web) i els estructura en un format homogeni per a centenars d'idiomes. Els textos originals ja vénen filtrats, dividits frase per frase i barrejats aleatòriament, cosa que ens proporciona una base de dades neta, imparcial i estandarditzada. huggingface

Aquest corpus està dividit en dos conjunts completament separats: un d'entrenament, per extreure l'estadística del llenguatge, i un de test per a l'avaluació. Abans d'extreure'n els trigrames, s'aplica una fase imprescindible de preprocessament. Totes les frases del text es netegen i es concatenen separades per dos espais en blanc. Això permet que el model pugui aprendre tant l'estructura interna de les paraules com les lletres que marquen els inicis i els finals, evitant que es formin seqüències falses basades només en salts de línia o espais irrellevants. Un cop preparat el text, es compten les freqüències dels trigrames per a cada idioma i es descarten aquells que apareixen poques vegades per optimitzar el rendiment.

3. Preprocessament

Per a preprocessar, agafem el contingut original de cada document de text i se sotmet a un rentat de cara per uniformar-lo. Això implica treure tots els números, convertir totes les lletres a minúscules i endreçar els espais perquè no n'hi hagi de sobrers entre paraules o al principi i al final del text. A més, s'aprofita per estandarditzar la separació entre les frases, canviant els salts de línia convencionals per un format específic, un doble espai, que facilita el seu tractament posterior. Això es fa així perquè el model que es construirà més endavant treballarà amb trigrames, i aquesta forma de separar les frases permet que els trigrames no es vegin afectats per espais innecessaris, mantenint la coherència en l'anàlisi de les seqüències de caràcters.

Un cop els textos estan nets, comença la segona fase, que consisteix a repartir el material perquè el model pugui aprendre i, posteriorment, ser examinat. Per fer-ho de manera justa i representativa, el codi agafa totes les frases de cada idioma del conjunt de train, les remena a l'atzar i les talla en dos blocs: un gran que conté el vuitanta per cent de la informació i un de més petit amb el vint per cent restant. Això és així perquè en el conjunt de dades donat originalment, les dades del test estavem presents al 100% en el conjunt d'entrenament donat. Doncs per evitar que el model aprengui a reconèixer les frases del test, es fa aquesta divisió, de manera que el model només veu el bloc gran durant l'entrenament i el bloc petit es reserva per avaluar la seva capacitat de generalització.

4. Implementació dels models

4.1 Lidstone Smoothing

El Lidstone Smoothing és una tècnica d'estimació de probabilitats que s'utilitza per evitar problemes de zero probabilitat en models de llenguatge. Aquesta tècnica consisteix a afegir un petit valor, anomenat λ, a les freqüències observades dels trigrames, assegurant que cap trigram no tingui una probabilitat de zero, fins i tot si no s'ha observat en el conjunt d'entrenament. Això permet que el model pugui generalitzar millor a dades noves i desconegudes, millorant així la seva capacitat de predicció.

4.1.1 Implementació

A la fase d'entrenament, el model calcula les freqüències dels trigrames per a cada idioma, així com els paràmetres B, que en el nostre cas serà nombre total de trigrames únics, per a cada idioma i N^t, el nombre total de trigrames observats, i guardem en un arxiu `.json` juntament amb el valor de λ utilitzat, que per defecte és 0.5. Aquesta informació és essencial per a la fase de predicció, on el model utilitza aquestes freqüències i paràmetres per calcular les probabilitats dels trigrames en els documents de test i determinar a quin idioma pertanyen. Un cop entrenat, el model es pot carregar des d'aquest arxiu `.json` per a realitzar les prediccions sense necessitat de tornar a entrenar-lo, facilitant així la seva reutilització i aplicació en diferents conjunts de dades.

La inferència es realitza, donat un text, dividint-lo en trigrames i calculant la probabilitat de cada trigram per a cada idioma utilitzant la fórmula del Lidstone Smoothing, que incorpora el valor de λ per ajustar les freqüències observades. Per tant, utlitzant les freqüències dels trigrames i els paràmetres B i N^t calculats durant l'entrenament, el model calcula la probabilitat de cada trigram per a cada idioma i, finalment, multiplica aquestes probabilitats per obtenir la probabilitat total del document per a cada idioma, o equivalentment, suma els logaritmes de les probabilitats per eficiència computacional:

$$P^T(e_i) = P^T_{\text{LID}}(e_i) = \frac{C^t(e_i) + \lambda}{N^t + \lambda B}$$

On, per MLE:

$$P(\hat{d}) = P(e^1, \ldots, e^s) = \prod_{j=1}^{s} P(e^j)$$

O equivalentment, en termes de logaritmes:

$$\log P(\hat{d}) = \sum_{j=1}^{s} \log P(e^j)$$

El model selecciona l'idioma que té la probabilitat més alta com a predicció final per al document de test. Per tal d'anar més enllà i refinar el valor de λ, es realitza una validació creuada, on el conjunt d'entrenament es divideix en sub-conjunts i el model es prova amb diferents valors de λ per determinar quin proporciona la millor precisió (accuracy) en els conjunts de validació. Aquesta etapa és crucial per optimitzar el rendiment del model i assegurar que no s'està sobreajustant als dades d'entrenament, permetent així una millor generalització a dades noves. Es proven diferents lambdes que van del 0.01 al 1, i es selecciona aquell que maximitza l'accuracy del model en els conjunts de validació, per cada idioma.

En termes de codi, el model es defineix com una classe `LanguageDetector`, que inclou els següents mètodes:

- `__init__`: Inicialitza el model amb un valor de λ, que per defecte és 0.5.
- `fit`: Entrena el model amb les dades d'entrenament, calculant els trigrames i les seves freqüències, així com els paràmetres B i N^t. Retorna un arxiu `.json` amb els paràmetres del model.
- `load_model`: Carrega un model preentrenat des d'un fitxer `.json`.
- `predict_text`: Realitza la predicció de l'idioma d'un frase donada, calculant les probabilitats dels trigrames i seleccionant l'idioma amb la probabilitat més alta.
- `refining_lambda`: Realitza una validació creuada per a refinar el valor de λ, provant diferents valors i seleccionant aquell que maximitza l'accuracy del model. Aquest mètode sobreescriu el valor de λ del model amb el valor optimitzat.
- `evaluate_model`: Avalua el rendiment del model amb les dades de test, calculant l'accuracy i la matriu de confusió.

4.1.2 Refinament del paràmetre lambda

Un cop implementat el model amb Lidstone Smoothing, es procedeix a refinar el paràmetre λ per optimitzar el rendiment del model. Aquesta etapa és crucial perquè el valor de λ afecta directament la suavització de les probabilitats dels trigrames i, per tant, la capacitat del model per generalitzar a dades noves. Entrem en detall de com funciona aquest mètode.

El mètode comença llegint el diccionari de freqüències que ja ha generat la fase de `fit` (on cada clau és un trigrama i el valor n'és la freqüència absoluta). Com que per fer la validació creuada necessitem fer particions, el mètode "descomprimeix" o aplana aquest diccionari en una única llista on els trigrames es repeteixen tantes vegades com indica el seu compte. D'aquesta manera, mantenim la distribució estadística real del corpus original de cada idioma. A continuació, remena (*shuffle*) la llista de manera aleatòria i la divideix en k parts iguals (per defecte 4). Això permet estructurar un procés iteratiu on, a cada pas, es fa servir un bloc diferent com a conjunt de validació (25% de les dades) mentre s'entrena el model amb la resta dels blocs sumats (el 75% de les dades restants). L'aportació més rellevant d'aquest mètode és la seva avaluació. Per a cada un dels candidats d'hiperparàmetres establerts a `lambdas_to_test` (0.001, 0.01, \dots), el codi prova a avaluar **individualment** cada trigrama de la partició de validació com si es tractés d'un minúscul text desconegut. S'extreu la probabilitat logarítmica d'aquest trigrama concret utilitzant el diccionari

generat al *train fold* combinat amb el valor del λ candidat actual (ja sigui atorgant probabilitat clàssica a trigrames coneguts, o aplicant l'atenuació logarítmica extrema als desconeguts, també anomenats casos *Out Of Vocabulary*).

No obstant això, mesurar únicament la probabilitat interna d'un idioma no ens diu fins a quin punt l'algoritme de predicció funciona bé realment; ens interessa una mètrica de precisió objectiva (Accuracy). Per això, per al trigrama que s'està avaluant en aquell moment precís, l'algorisme inspecciona iterativament els paràmetres de **tots els altres idiomes presents al JSON original**, i calcula la puntuació que ells (amb les seves configuracions constants i globals) li assignarien. Només si l'idioma original assoleix una probabilitat de pertinença **estrictament superior** (el resultat logarítmic és menys negatiu) a les probabilitats obtingudes amb els altres idiomes, es comptabilitza un encert (`correct_predictions += 1`). Finalitzats els k cicles d'entrenament i validació per al candidat λ, es calcula la mitjana global d'aquestes exactituds creuades, obtenint un marge de seguretat en percentatge (l'Accuracy).

Al final del bucle d'avaluació de la llista de candidats, la funció compara el rendiment numèric de tots els λ avaluats, seleccionant el que hagi aportat l'Accuracy mitjana més elevada. Si detecta millores amb el nou hiperparàmetre respecte del que tenia anteriorment, la propietat `self.model_params` s'actualitza i el codi obre de nou el fitxer original passat per argument, sobreescrivint el seu contingut per desar de manera permanent aquest "tunning" intern. Els resultats d'aquest procés es poden observar a la taula següent, on es mostren els valors de λ provats i les seves corresponents precisions (Accuracy) obtingudes a través de la validació creuada:

Resultats del Refinament del Paràmetre Lambda per Idioma

Idioma	λ = 0.001	λ = 0.01	λ = 0.05	λ = 0.1	λ = 0.3	λ = 0.5	λ = 0.7	λ = 1.0
deu	50.90%	50.90%	**50.90%**	50.87%	50.86%	50.87%	50.83%	50.83%
eng	44.12%	44.12%	44.12%	44.13%	44.11%	44.13%	44.14%	**44.15%**
fra	46.61%	46.61%	46.61%	46.60%	46.61%	46.59%	46.60%	**46.62%**
ita	51.93%	51.93%	51.94%	51.94%	**51.94%**	51.92%	51.93%	51.79%
nld	49.54%	49.54%	49.54%	**49.55%**	49.46%	49.47%	49.41%	49.43%
spa	47.81%	**47.81%**	47.80%	47.80%	47.79%	47.79%	47.79%	47.74%

Taula 1: Accuracy obtinguda durant la validació creuada per a diferents valors de lambda.

A simple vista, les precisions obtingudes durant el procés de validació creuada (amb uns percentatges que oscil·len únicament entre el 44% i el 51%) poden semblar inusualment baixes per a un model que posteriorment demostra ser pràcticament perfecte. No obstant això, aquest fenomen es pot explicar fàcilment si tenim en compte la exactament què s'està avaluant en aquesta fase.

Durant aquesta fase d'optimització, el sistema no està intentant classificar frases senceres ni paràgrafs, sinó que se li exigeix endevinar l'idioma a partir de **trigrames individuals completament aïllats**. Des d'un punt de vista estadístic, intentar deduir a quina llengua pertany una seqüència de només tres caràcters, sense cap mena de context, és una tasca altament ambigua i, sovint, impossible.

Això es fa evident quan pensem en conjuncions, articles, preposicions curtes o afixos verbals que es comparteixen fonèticament i estructuralment entre múltiples idiomes europeus. Per exemple, trigrames com `" la"`, `" de"`, o fins i tot espais intermedis com `" a "`, apareixen de manera abundant en espanyol, italià i francès. Quan l'algorisme intenta validar un d'aquests trigrames pertanyent originalment al conjunt d'entrenament de l'espanyol, es veu obligat a comparar les probabilitats. Si resulta que el model italià presenta una freqüència històrica lleugerament més alta per a aquella seqüència concreta de tres lletres, la predicció es marcarà automàticament com un

error (fals negatiu), malgrat que el trigrama inicial formava part d'una paraula espanyola totalment legítima.

És per aquest motiu que l'anglès, que comparteix molts caràcters estructurals amb les altres llengües però presenta certes particularitats lèxiques, s'endú l'accuracy més baixa de la taula (al voltant del 44%).

4.1.3 Anàlisi dels resultats i errors

Primer de tot visualitzem la matriu de confusió obtinguda després d'aplicar el model amb Lidstone Smoothing al conjunt de test, sense refinar el paràmetre λ:

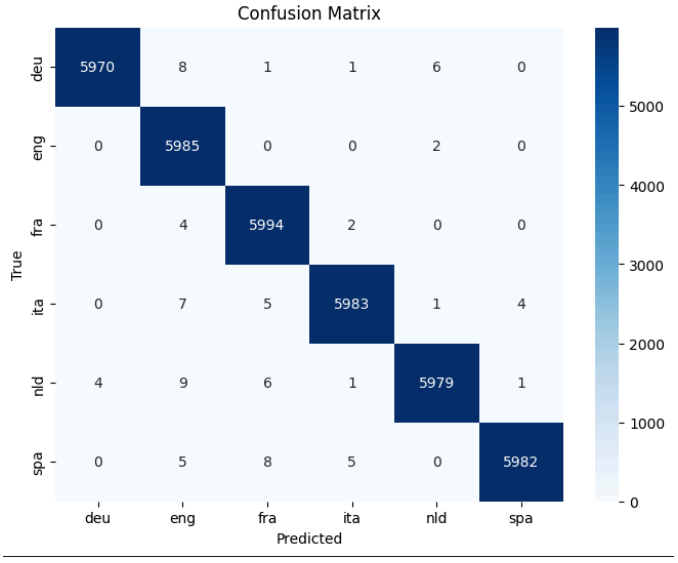

Figura 1: Matriu de confusió del model amb Lidstone Smoothing, sense refinar lambda

Veiem que el model ja mostra un rendiment molt alt, amb una forta concentració de valors a la diagonal principal (les caselles blau fosc), indicant que el model encerta de manera aclaparadora l'idioma correcte. No obstant això, encara es poden observar alguns errors residuals (nombres fora de la diagonal) que permeten analitzar les relacions i similituds lingüístiques que confonen el model. Provem d'avaluar el model amb el valor de λ que ha proporcionat la millor precisió durant la validació creuada, i observem com millora encara més l'accuracy global, arribant a percentatges pràcticament perfectes per a cada idioma:

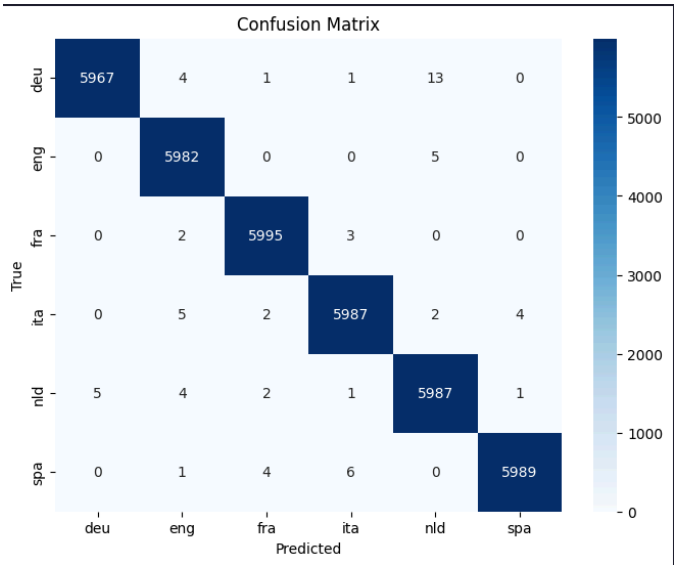

Figura 2: Matriu de confusió del model amb Lidstone Smoothing.

Veiem que hi ha una millora de la quantitat d'encerts, però és mínima, ja que el model ja era molt bo abans de refinar el paràmetre λ. Pel que fa a l'accuracy, les diferències són pràcticament inapreciables, l'accuracy del primer model era del 99.7982% i el model refinat amb el millor λ és del 99.8167%, una millora de només 0.02 punts percentuals, que es pot considerar negligible en termes pràctics, però que demostra que el procés de validació creuada ha ajudat a optimitzar lleugerament el model. Per tant, passem a analitzar en detall el segon model:

El primer que destaca és la forta concentració de valors a la diagonal principal (les caselles blau fosc). Això significa que el model encerta de manera aclaparadora l'idioma correcte. Per a cada un dels 6 idiomes, el model ha avaluat 6.000 mostres (ja que la suma de cada fila és 6.000). Les xifres d'encert oscil·len entre 5.970 (alemany i neerlandès, els "pitjors") i 5.994 (francès, el millor), cosa que suposa una exactitud per a cada idioma de:

- Alemany (`deu`): 99.73%
- Anglès (`eng`): 99.97%
- Francès (`fra`): 99.97%
- Italià (`ita`): 99.72%
- Neerlandès (`nld`): 99.65%
- Espanyol (`spa`): 99.70%

Aquesta diferència abismal respecte al ~50% obtingut durant el `refining_lambda` s'explica perquè ara no s'està avaluant l'idioma d'un sol trigrama aïllat (3 lletres descontextualitzades), sinó l'acumulació de probabilitats de tots els trigrames d'un text o una frase sencera, on l'estadística esdevé molt robusta. Els errors (nombres fora de la diagonal) són residuals, però permeten observar les relacions i similituds lingüístiques que confonen el model:

La principal font d'error implica l'Anglès (`eng`): Si mirem la columna `eng`, veiem que 8 textos alemanys, 4 francesos, 7 italians, 9 neerlandesos i 5 espanyols s'han classificat erròniament com a anglès. Això podria deure's a la presència d'anglicismes internacionals, noms propis o URL dins els textos de prova d'aquests idiomes, o bé a que el model en anglès tingui una distribució de lletres molt neutra i dominant. També podem veure la **relació Germànica (`deu` vs `nld`):** Es noten lleugeres confusions creuades entre l'alemany i el neerlandès per la seva mateixa arrel lingüística. 4 textos neerlandesos (`nld`) s'han predit com a alemany (`deu`), i 6 textos alemanys s'han predit com a neerlandès. Finalment podem veure la**relació Romànica:** També s'observen confusions menors entre les llengües derivades del llatí. L'espanyol i el francès es confonen mútuament 8 cops; l'espanyol i l'italià es confonen 5 i 4 cops respectivament.

Si analitzem les frases mal classificades, podem veure certs patrons en les frases que el model ha etiquetat erròniament, podem observar diferents patrons que expliquen aquestes confusions, i els hem classificat en diferents categories:

1. **Frases que contenen noms propis estrangers, respecte la frase original:** Aquestes frases són les més comunes de fallar, sobretot quan la llengua de la frase original no és l'anglès, ja que l'anglès és un idioma molt dominant i internacional, i molts noms propis, marques, llocs o termes tècnics són d'origen anglès. Per exemple:

```
Frase mal classificada: 'freitag, . januar kanye west und paul mccartney bringen gemeinsame single heraus kanye west rappt nun auch mit paul mccartney (archiv).' (True: deu -> Predicted: eng)

Frase mal classificada: 'anche air france, klm, thai airways, easyjet e ryanair hanno oggi cancellato i voli.' (True: ita -> Predicted: eng)

Frase mal classificada: 'de band bestaat uit zanger/gitarist james bagshaw, gitarist adam smith, bassist thomas warmsley en drummer samuel toms.' (True: nld -> Predicted: eng)

Frase mal classificada: 'temas como 'tonight', 'dirty dancer', 'lloro por ti', 'scape', 'hero', 'i like it', fueron parte del repertorio musical.' (True: spa -> Predicted: eng)

Frase mal classificada: 'de grey's anatomy à brothers sisters" - yahoo!' (True: fra -> Predicted: eng)
```

Però també hi ha un cas d'una frase en anglès que conté noms propis d'origen neerlandès, i el model l'ha classificat com a neerlandès:

```
Frase mal classificada: 'strong visuals (robrecht heyvaert, cinematography) and sound (hannes de maeyer, composer; joeri verspecht, sound engineer).' (True: eng -> Predicted: nld)
```

2. **Frases que no queda clar quin idioma són, perquè contenen paraules molt comunes o internacionals i perquè són molt curtes:** Aquestes frases, a més de ser molt curtes, contenen paraules que són molt comunes en diversos idiomes o que són internacionals. Això fa que el model no tingui prou informació per distingir clarament a quin idioma pertanyen, i per tant es confonen amb l'anglès o amb altres idiomes. Per exemple:

```
Frase mal classificada: 'champions o europa league?' (True: ita -> Predicted: fra)
Frase mal classificada: 'ja, mein onkel peter.' (True: deu -> Predicted: nld)
Frase mal classificada: '"dal sud", dice.' (True: ita -> Predicted: spa)
Frase mal classificada: 'assassin's creed iv (uplay-code) für , euro.' (True: deu -> Predicted: eng)
```

3. **Frases que contenen caràcters estrangers o símbols que no són habituals en l'idioma original:** Aquestes frases contenen caràcters o símbols que no són habituals en l'idioma original, com ara caràcters d'altres llengües:

```
Frase mal classificada: 'ali adnan kadhim nassir al-tameemi (arabisch : علي عدنان كاظم ناصر التميمي) (adhamiyah, december ) - alias ali adnan - is een irakees voetballer die bij voorkeur als linksback speelt.' (True: nld -> Predicted: eng)

Frase mal classificada: 'ю. левянт moscú, de febrero, ria novosti.' (True: spa -> Predicted: ita)

Frase mal classificada: 'asî es, aûn nos quedan varios dîas :d.' (True: spa -> Predicted: fra)

Frase mal classificada: 'nyborg: hvad er din foretrukne bevaringsværdige bygning i nyborg kommune?' (True: deu -> Predicted: eng)

Frase mal classificada: '」 クリップした記事をmyページから読むことができます here's my content　オトバンクは月日、完全匿名性でライトノベルやアニメなどに興味のある“オタク”ユーザー向けのチャット＆コミュニケーションアプリ「にじがくっ！' (True: eng -> Predicted: nld)
```

4. **Errors del model:** Aquí en aquest cas, el model ha comès un error de classificació on queda clar en quin idioma està escrita la frase, però el model l'ha etiquetada erròniament. Per exemple:

```
Frase mal classificada: 'joder, tiene que molar mazo tener un coche que te diga "shiu shiuiuiu hola maiquel, shiuu shiuiu", pero con la voz de chiquito de la calzada.' (True: spa -> Predicted: ita)

Frase mal classificada: 'american and iranian diplomats began meeting last week in vienna.' (True: eng -> Predicted: nld)

Frase mal classificada: 'pilar vive a plenitud ser madre.' (True: spa -> Predicted: fra)

Frase mal classificada: '"¡va por ti!, ¡ay, que nos la han quitao!' (True: spa -> Predicted: fra)

Frase mal classificada: 'marzo: estalla un conflicto civil.' (True: spa -> Predicted: ita)

Frase mal classificada: 'en fin, a ver si espabilamos ¡hombre!' (True: spa -> Predicted: fra)
```

La llengua més comuna en aquests errors és el castellà, que es confon amb l'italià i el francès, probablement perquè comparteixen moltes paraules i estructures similars, i perquè el

model pot tenir més dificultats per distingir-los quan les frases són curtes o contenen paraules comunes.

4.2 Interpolation Smoothing

El model d'Interpolation Smoothing s'ha utilitzat com una millora respecte al suavitzat de Lidstone, ja que permet combinar informació de diferents nivells de n-grames per aconseguir prediccions més estables. La idea principal d'aquest mètode és que no sempre és necessari dependre únicament de la freqüència del trigrama complet, sinó que també pot ser útil considerar informació parcial quan el trigrama exacte no apareix en el corpus d'entrenament.

4.2.1 Implementació

En concret, la probabilitat d'un trigrama es calcula com una combinació lineal de quatre components diferents: la probabilitat del trigrama complet, la del bigrama associat (els dos últims caràcters del trigrama), la del unigrama corresponent i, finalment, una probabilitat uniforme que actua com a salvaguarda quan el model es troba amb seqüències desconegudes.

Matemàticament, aquesta combinació es representa com:

$$P^{interp}(t) = \lambda^3 P^3(t) + \lambda^2 P^2(t) + \lambda^1 P^1(t) + \lambda^0 P^u$$

On cada terme té el següent significat:

- $P^3(t)$ és la probabilitat estimada del trigram observat dins del corpus d'entrenament.
- $P^2(t)$ correspon a la probabilitat del bigram associat, format pels dos darrers caràcters del trigram.
- $P^1(t)$ representa la probabilitat del unigram associat al darrer caràcter.
- $P^u = \frac{1}{V}$ és una distribució uniforme sobre l'alfabet de mida V, que ajuda a evitar probabilitats zero en casos on la seqüència no s'ha observat mai.

Els coeficients λ^i han de complir que la seva suma sigui igual a 1 i que cap d'ells sigui negatiu, de manera que la combinació resulti en una distribució de probabilitat vàlida.

Durant l'entrenament del model, es calculen els comptadors de freqüència dels diferents nivells de n-grames per a cada idioma. Posteriorment, aquests comptadors s'utilitzen juntament amb els pesos d'interpolació per obtenir una estimació global de la probabilitat del document.

En termes de codi, definim el model com una altra classe, `InterpolationLanguageModel`, amb els seguents mètodes:

- `__init__`: inicialitza el model amb valors de lambda per defecte.
- `fit`: permet entrenar el model a partir d'un conjunt de trigrames emmagatzemats en format `.json`, calculant les freqüències dels diferents n-grames necessaris per estimar les

probabilitats condicionals. Internament, el mètode `_fit_from_dict` construeix els comptadors estadístics d'unigrames, bigrames i trigrames, així com els comptadors de context associats, que són necessaris per a l'estimació correcta de les probabilitats condicionals.

- `load_model`: carrega un model preentrenat dins d'un fitxer `.json`.
- `predict_text`: realitza la classificació d'un text preprocessat calculant la probabilitat logarítmica interpolada per a cada idioma i seleccionant l'idioma amb la puntuació més alta.
- `_interpolated_log_prob`: implementa el càlcul central del model, estimant la probabilitat logarítmica d'un trigrama mitjançant estimadors de màxima versemblança condicionals i aplicant els pesos d'interpolació.
- `_score_text`: calcula la puntuació global d'un document sumant les contribucions logarítmiques de tots els trigrames presents.
- `evaluate`: permet avaluar el rendiment del model sobre un corpus de prova en format `.json`.

4.2.2 Anàlisi dels resultats i errors

Un cop entrenat el model, procedim a validar-lo amb el corpus d'entrenament. Comencem observant la matriu de confusió obtinguda:

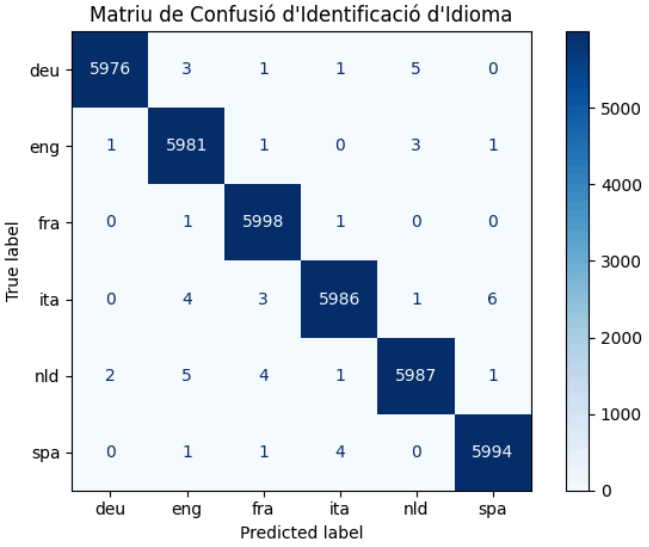

Figura 3: Matriu de confusió del model amb Lidstone Smoothing.

Observem que, al igual que en el model anterior, obtenim un rendiment gairebé perfecte. Per a cada idioma, el model avalua 6.000 mostres i les xifres d'encert per idioma són:

- Alemany (`deu`): 99,6%
- Anglès (`eng`): 99,68%
- Francès (`fra`): 99,97%
- Italià (`ita`): 99,77%
- Neerlandès (`nld`): 99,78%
- Espanyol (`spa`): 99,9%

Aquests resultats són molt similars als que vam obtenir amb el model de Lidstone, la qual cosa ens indica que tots dos models s'acaben comportant de manera gairebé equivalent sobre aquest conjunt de dades. Tot i així, sí que s'aprecien petites diferències entre els dos: per exemple, l'espanyol millora lleugerament passant del 99,70% al 99,90%, i el francès pràcticament no comet cap error. En canvi, l'alemany pateix una petita davallada respecte al Lidstone, baixant del 99,73% al 99,60%. Aquestes diferències, però, són tan petites que no permeten concloure que un model sigui clarament superior a l'altre; en tot cas, apunten que la interpolació afegeix una mica de robustesa en alguns idiomes i perd una mica en d'altres, segurament en funció de com de ben representats estan els n-grames de cada nivell en el corpus d'entrenament.

Podem analitzar també les mètriques de rendiment:

Mètriques de Rendiment per Idioma al Conjunt de Test

Classe	Precision	Recall	F1-score	Support
deu	1.00	1.00	1.00	5986
eng	1.00	1.00	1.00	5987
fra	1.00	1.00	1.00	6000
ita	1.00	1.00	1.00	6000
nld	1.00	1.00	1.00	6000
spa	1.00	1.00	1.00	6000

Taula 2: Mètriques detallades d'avaluació del model.

Les mètriques de precisió, exhaustivitat i F1-score donen totes un valor de 1 per a tots els idiomes. Això vol dir que el model no només encerta gairebé sempre quan prediu un idioma concret (alta precisió), sinó que a més és capaç de detectar pràcticament totes les mostres d'aquell idioma sense deixar-ne escapar gaires (alt recall). El fet que el F1-score, que combina ambdues mètriques en una sola, sigui també 1 confirma que no hi ha cap idioma que penalitzi especialment el model ni en un sentit ni en l'altre.

En definitiva, podem concloure que el model d'Interpolation Smoothing és perfectament apte per a la tasca de detecció d'idioma en aquest conjunt de dades, i que la seva capacitat de discriminació entre les sis llengues considerades és altíssima. La combinació de trigrames, bigrames, unigrames i la distribució uniforme proporciona una estimació de probabilitat suficientment robusta per gestionar bé tant les seqüències vistes durant l'entrenament com aquelles que apareixen per primera vegada al conjunt de test, sense necessitat de recórrer a cap mena de penalització addicional per als casos desconeguts. De fet, el rendiment obtingut és tan elevat que no hem considerat necessari realitzar una cerca exhaustiva d'hiperparàmetres, a diferència del que vam fer amb el model de Lidstone. Qualsevol millora derivada d'un ajust fi dels pesos λ seria, en el millor dels casos, marginal i difícilment apreciable sobre aquestes dades.

Pero per molt bo que sigui el model, cal analitzar en quins casos s'equivoca, per identificar patrons i errors que ens puguin ajudar a millorar-lo. Com hem fet amb el model Lidstone, classifiquem els errors en diferents categories:

1. **Frases massa curtes:** En alguns casos tenim frases que són molt curtes. Quan això passa, hi ha una manca d'informació, ja que el model disposa de pocs trigrames per estimar la probabilitat d'un idioma. Quan el nombre de trigrames és baix, les diferències entre idiomes es tornen molt petites, cosa que dificulta la classificació correcta. Aquesta és una de les limitacions principals dels models basats en n-grames de caràcters. Alguns exemples d'aquest comportament són:

```
[REAL=eng | PRED=spa] $. per meal.

[REAL=deu | PRED=nld] ja, mein onkel peter.

[REAL=ita | PRED=fra] champions o europa league?
```

2. **Frases amb fragments en un altre idioma:** Hi han algunes frases que contenen fragments escrits en un altre idioma, ja sigui per noms propis, cites, títols o expressions d'altres llengues. En aquests casos el model pot confondre's e identificar erròniament l'idioma, ja que la barreja linguística pot distorsionar la distribució de trigrames. Aquí tenim alguns exemples concrets:

```
[REAL=deu | PRED=eng] mit channing tatum, amanda seyfried. the last
song ( mit dir an meiner seite) mit miley cyrus, liam hemsworth.

[REAL=eng | PRED=nld] daniel pollack-pelzner teaches english at
linfield college, in oregon.

[REAL=eng | PRED=nld] strong visuals (robrecht heyvaert,
cinematography) and sound (hannes de maeyer, composer; joeri
verspecht, sound engineer).

[REAL=spa | PRED=eng] the angry beavers los castores cascarrabias
(the angry beavers) es una serie animada creada por mitch schauer
para el canal nickelodeon en .

[REAL=nld | PRED=eng] geschiedenis thai airways international is
opgericht in door thai airways en scandinavian airlines system.

[REAL=ita | PRED=spa] 'el mundo deportivò, altro quotidiano vicino al
club blaugrana, titola "dios del futbol".

[REAL=ita | PRED=eng] roger waters: anche in europa 'the wall' dei
pink floyd?
```

Aquest error es podria reduir fent un preprocessament més exhaustiu del text d'entrada. Per exemple, es podrien eliminar petits fragments entre cometes (que normalment corresponen a cites) o noms propis. Aquest mètode ajudaria a reduir la barreja de llengues i a millorar la discriminació entre classes.

3. **Errors del model:** En alguns casos, encara tenint una frase extensa escrita en un únic idioma, el model falla igualment. Aquí tenim alguns exemples concrets:

```
[REAL=deu | PRED=nld] het consumentenvertrouwen is er in januari
geklommen naar het hoogste niveau in elf jaar.

[REAL=eng | PRED=nld] what is seven plus zero?

[REAL=deu | PRED=nld] onlangs was er een beachvolleybaltoernoei in
baal, de heimat van nys.

[REAL=eng | PRED=fra] the cozy arrangement raises big red flags.

[REAL=spa | PRED=fra] pilar vive a plenitud ser madre.
```

Veiem que això només passa entre l'alemany i el neerlandès. Això és perque aquestes dues llengues són molt semblants, tant a nivell morfològic com de distribució de trigrames. Quan dues llengües comparteixen moltes seqüències de caràcters, el valor de la versemblança logarítmica que calcula el model és molt similar per a ambdues classes. En aquests casos, la decisió final depèn de diferències molt petites en el score total, cosa que fa que el classificador sigui especialment sensible al smoothing i a la variabilitat del corpus d'entrenament.

5. Conclusions

Aquesta pràctica ha permès dissenyar, implementar i avaluar dos models estadístics de detecció d'idioma basats en trigrames de caràcters, aplicant les tècniques de suavització Lidstone i Interpolation. Els resultats obtinguts han estat altament satisfactoris, amb una precisió global altíssima en els dos models per a tots els idiomes considerats, la qual cosa valida l'enfocament basat en n-grames de caràcters com una solució robusta i eficient per a aquesta tasca.

Pel que fa a la comparació entre els dos models, els resultats han estat bastant similars. L'Interpolation Smoothing, teòricament més expressiu per la seva capacitat de combinar informació de múltiples nivells de n-grames, no ha aconseguit una millora apreciable respecte al Lidstone en aquest conjunt de dades. Això suggereix que, davant d'un corpus suficientment gran i net com el de Leipzig, el suavitzat de Lidstone ja és capaç de gestionar adequadament els trigrames no observats, i la informació addicional aportada pels bigrames i unigrames no resulta determinant.

L'anàlisi qualitativa dels errors ens ha mostrat que la majoria de classificacions incorrectes no responen a limitacions estructurals del model, sinó a casos inherentment complexos: frases molt curtes, textos que barregen idiomes per la presència de noms propis, títols o expressions en anglès, i frases amb caràcters especials d'alfabets no llatins. Els dos idiomes que generen més confusió mútua són l'alemany i el neerlandès, resultat esperable donada la seva proximitat tipològica i el seu origen germànic comú.

De cara a treballs futurs, les línies de millora passarien per un preprocessament més acurat que gestioni de manera explícita els fragments multilingües i els noms propis, per l'exploració de models amb n-grames de longitud variable, o per la combinació de característiques a nivell de caràcter amb informació lèxica per capturar millor les particularitats de cada idioma.

En conjunt, la pràctica ha permès constatar que els models de llenguatge basats en n-grames de caràcters constitueixen una eina sòlida i computacionalment eficient per a la detecció d'idioma. La seva fortalesa rau en la capacitat d'explotar la riquesa estadística d'un corpus suficientment representatiu, que permet capturar les distribucions de caràcters pròpies de cada llengua sense necessitat de recursos lingüístics addicionals com diccionaris o analitzadors morfològics.